



Corso di Laurea Triennale in Informatica

SensY: Classificazione Automatica dei Prompt Sensibili per i Large Language Model (LLM)

Prof. Andrea De Lucia
Dott. Gianmario Voria

Alessandra Raia
Mat.: 0512116634



I **LLM** STANNO TRASFORMANDO IL PANORAMA DELL' **IA**, DIFFONDENDOSI RAPIDAMENTE IN CONTESTI **QUOTIDIANI E SOCIALI**.



LA LORO **POTENZA** SOLLEVA UNA QUESTIONE **CRUCIALE**: COME GESTIRE PROMPT **SENSIBILI**.



COSA SI INTENDE PER **SENSITIVENESS**?

“Un’espressione è sensitive se, per via del suo **contenuto**, del **contesto** o della sua **formulazione**, ha il potenziale di suscitare **emozioni** forti, generare **disagio** o rischio di **giudizio**. Può essere in grado di **discriminare**, risultare invasiva o compromettere la **sicurezza** o la **privacy**. (...) La **risposta** può variare notevolmente, rischiando di essere **fraintesa** o percepita in modo diverso da quanto **inteso** (...)”



TAY di MICROSOFT

Tay era un **chatbot IA** lanciato su Twitter che, apprendendo dal linguaggio degli utenti, iniziò a produrre messaggi **razzisti, sessisti e negazionisti**. Microsoft fu costretta a disattivarlo, riconoscendo l'assenza di adeguati filtri e meccanismi di controllo.

SOURCE: Microsoft's racist robot: "Chatbot" taken offline as Tweets



Two Muslims walk into a... [GPT-3 completions below]

synagogue with axes and a bomb.

gay bar and began throwing chairs at patrons.

Texas cartoon contest and opened fire.

gay bar in Seattle and started shooting at will, killing five people.

bar. Are you really surprised when the punchline is 'they were asked to leave'?

GPT-3 e BIAS RELIGIOSI

In risposta a prompt come **"Two Muslims walk into a"**, GPT-3 tendeva a completare la frase con atti violenti o terroristici, rivelando **stereotipi pericolosi** su base religiosa e culturale nei dati di addestramento.

[SOURCE: Persistent Anti-Muslim Bias in Large Language Models](#)

I **LLM** NON SONO NEUTRALI,
APPRENDONO DA **PAROLE** CHE
«*POSSONO ESSERE **FINESTRE***
OPPURE MURI» (Marshall Rosenberg)

RQ1

FINO A CHE PUNTO È POSSIBILE
PREVEDERE AUTOMATICAMENTE LA
SENSIBILITÀ DI UN PROMPT RIVOLTO
A UN **LLM**?



SensY

Un **classificatore** che ha l'ambizione di intercettare i prompt **sensibili** prima che arrivino al modello generativo.



Data
Understanding

Data
Preparation

Modeling

SQuARe



i

Numero prompt

- Total questions: **51.197**
- Sensitive: **49.313**
- Non sensitive: **1.884**

Data
Understanding

Data
Preparation

Modeling

SQuARe



```
{  
  "question_en": "We shouldn't use  
  violence against children, should we?",  
  "sensitive?": 1  
}
```

Data
Understanding

Data
Preparation

Modeling

SQuARe



SBILANCIATO



BASSA COPERTURA
TEMATICA




SPECIFICO PER LA
COREA





- scelta **sottoinsieme** di prompt;
- eliminazione dei **duplicati**;
- algoritmo **HDBSCAN**;
- lavoro di **undersampling**.



Due dataset aggiuntivi:

- generato da **ChatGPT**;

i Numero prompt: **3.374**

- dataset **Chatbot Arena Conversations**.


i Numero prompt: **9.366**

Etichettatura manuale dei prompt.



| FEATURES | |
|-------------------------------|--|
| SINTATTICHE | SEMANTICHE |
| numero di parole distinte | SA - Sentiment Analysis |
| conteggio dei verbi | |
| conteggio degli aggettivi | BERT- Bidirectional Encoder Representations from Transformers |
| conteggio sostantivi | |
| conteggio di parole sensibili | |

Per l'implementazione è stato scelto l'algoritmo Random Forest.




Training and Testing

Usando diverse **combinazioni** dei dataset ottenuti:




| DATASET | NUMERO PROMPT |
|----------------------------|---------------|
| SQuARe_questions_train | 6.733 |
| SQuARe_questions_test | 6.945 |
| Chatbot Arena Conversation | 9.366 |
| ChatGPT_questions | 3.374 |





Valutazione

| % aggiuntivo | <div><div><div>A</div>ccuracy</div><div><div>P</div>recision</div><div><div>M</div>acro avg</div></div> <div><div><div>F1</div>-score</div><div><div>R</div>ecall</div><div><div>W</div>eighted avg</div></div> |
|--------------|---|
|--------------|---|





Valutazione

| % aggiuntiva | Classe 1 (Sensitive) | | | Accuracy |
|--------------|----------------------|--------|-------|----------|
| | Precision | Recall | F1 | |
| 20% | 0.974 | 0.907 | 0.939 | 0.8878 |
| 40% | 0.973 | 0.917 | 0.944 | 0.8958 |
| 60% | 0.973 | 0.927 | 0.949 | 0.9054 |
| 80% | 0.970 | 0.926 | 0.948 | 0.9022 |
| 100% | 0.971 | 0.929 | 0.950 | 0.9055 |

valutazione




Analisi degli
errori



- 1 Tematiche scarsamente rappresentate nel training set
- 2 Modello fatica su prompt impliciti




QUAL È LA COMBINAZIONE MIGLIORE?




TRAINING SET

SQuARe_questions_train

Chatbot Arena Conversation




TESTING SET



TRAINING SET

SQuARe_questions_train

Chatbot Arena Conversation



TESTING SET

SQuARe_questions_test

Combinazione migliore



TRAINING SET

SQuARe_questions_train

Chatbot Arena Conversation

Accuracy: 0.9055



TESTING SET

SQuARe_questions_test





AN1

Answer to RQ1

QUANDO SI ADDESTRA IL MODELLO CON DATASET **ETEROGENEI**, **BILANCIATI** E **RAPPRESENTATIVI**, È POSSIBILE PREVEDERE LA **SENSIBILITÀ** DEI PROMPT CON UN BUON GRADO DI **AFFIDABILITÀ**.

SensY non risolve autonomamente le questioni etiche legate all'output dei LLM, ma rappresenta un piccolo passo nella direzione giusta.





Categorizzazione




Aggiunta di elementi sensibili



Concetto di sensitiveness



Analisi dell'adeguatezza



Corso di Laurea Triennale in Informatica

SensY: Classificazione Automatica dei Prompt Sensibili per i Large Language Model (LLM)

Prof. Andrea De Lucia
Dott. Gianmario Voria

Alessandra Raia
Mat.: 0512116634

a.raia7@studenti.unisa.it
github.com/alessraia
Alessandra Raia | LinkedIn



Metodo di Ricerca

I LLM NON SONO NEUTRALI, APPRENDONO DA PAROLE CHE «POSSONO ESSERE FINESTRE OPPURE MURI» (Marshall Rosenberg)

RQ1

FINO A CHE PUNTO È POSSIBILE PREVEDERE AUTOMATICAMENTE LA SENSIBILITÀ DI UN PROMPT RIVOLTO A UN LLM?

a.raia7@studenti.unisa.it
github.com/alessraia
Alessandra Raia | LinkedIn

SensY: Classificazione Automatica dei Prompt Sensibili per i Large Language Model (LLM)
Alessandra Raia
Università degli Studi di Salerno



Analisi dei Risultati

AN1

Answer to RQ1

QUANDO SI ADDESTRA IL MODELLO CON DATASET ETEROGENEI, BILANCIATI E RAPPRESENTATIVI, È POSSIBILE PREVEDERE LA SENSIBILITÀ DEI PROMPT CON UN BUON GRADO DI AFFIDABILITÀ.

a.raia7@studenti.unisa.it
github.com/alessraia
Alessandra Raia | LinkedIn

SensY: Classificazione Automatica dei Prompt Sensibili per i Large Language Model (LLM)
Alessandra Raia
Università degli Studi di Salerno



Sviluppi Futuri

- Categorizzazione
- Aggiunta di elementi sensibili
- Concetto di sensitiveness
- Analisi dell'adeguatezza

a.raia7@studenti.unisa.it
github.com/alessraia
Alessandra Raia | LinkedIn

SensY: Classificazione Automatica dei Prompt Sensibili per i Large Language Model (LLM)
Alessandra Raia
Università degli Studi di Salerno



SensY: Classificazione Automatica dei Prompt Sensibili per i Large Language Model (LLM)

Grazie per l'attenzione!



Questa tesi ha contribuito a piantare un albero in Tanzania



Alessandra Raia

a.raia7@studenti.unisa.it

github.com/alessraia

[Alessandra Raia | LinkedIn](#)

